



LE GUIDE DU JEUNE CHERCHEUR

“If you torture the data long enough, it will confess to anything”

Ronald H. Coase

Nom : BOUSSARD

Prénom : Lucas

Contact : lucas.bssd@gmail.com

Université Paris Nanterre – UFR STAPS

Laboratoire des Interactions, Cognition, Action et Émotions

Table des matières

CHAPITRE 1. CREDIBILITE ET QUALITES PSYCHOMETRIQUES.....	1
Chapitre 1.1. Fidélité	1
Chapitre 1.1.1. Pourquoi la fidélité ?	1
Chapitre 1.1.2. Quel seuil utilisé ?	2
Chapitre 1.2. Validité.....	4
Chapitre 1.2.1. Validité de construit	4
Chapitre 1.2.2. Validité interne.....	4
Chapitre 1.2.3. Validité externe	5
Chapitre 1.2.4. Validité inférentielle.....	6
CHAPITRE 2. METHODOLOGIE.....	7
Chapitre 2.1 Design et puissance.....	7
Chapitre 2.1.1. Définition et compréhension	7
Chapitre 2.1.2. Quel est le problème ?	7
Chapitre 2.1.3. Comment améliorer sa puissance ?	8
Chapitre 2.1.4. Que choisir comme taille d'effet ?	10
Chapitre 2.2 Taille d'effet.....	12
Chapitre 2.2.1. Caractéristiques tailles d'effet	12
Chapitre 2.2.2. Revue des tailles d'effets	13
Chapitre 2.2.3. Simples vs standardisées.....	14
Chapitre 2.2.4. Interprétations	15
Chapitre 2.2.5. Cas des effets nuls.....	16
Chapitre 2.2.6. Constats généraux.....	17
Chapitre 2.3 Intervalles de confiance	21
Chapitre 2.4. Réplication	22
Chapitre 2.4.1. Définition	22
Chapitre 2.4.2. Réussite ou échec ?.....	22
Chapitre 2.4.3. Implications.....	23
CHAPITRE 3. TESTS STATISTIQUES	25
Chapitre 3.1 NHST	25
Chapitre 3.1.1. Historique.....	25
Chapitre 3.1.2. Incompréhension	27
Chapitre 3.1.3. Les degrés de liberté du chercheur	29
Chapitre 3.1.4. Publication	30
Chapitre 3.1.5. Utilisation de la p-value	32
Chapitre 3.2 Tests statistiques et conditions d'applications	33
Chapitre 3.2.1. Quel test statistique ?	33
Chapitre 3.2.2. Pourquoi conditions d'applications ?.....	34
Chapitre 3.2.3. Normalité	35
Chapitre 3.2.4. Variance	37

Chapitre 3.3 Outliers	39
Chapitre 3.3.1. Méthode visuelle	39
Chapitre 3.3.2. Méthodes statistiques.....	40
Chapitre 3.3.3. Clusters.....	41
 REFERENCES CHAPITRE 1	 43
 REFERENCES CHAPITRE 2	 45
 REFERENCES CHAPITRE 3	 49

TO DO LIST

Intérêt scientifique de la recherche

- ☐ Définir le construit d'intérêt (objet de recherche). Ex : perception visuelle.
- ☐ Définir une problématique de recherche. Ex : Construction de la perception visuelle.
- ☐ Formulation d'hypothèses théoriques. Ex : L'action motrice construit la perception.

Paradigme expérimental

- ☐ Opérationnalisation de l'hypothèse. Ex : Utilisation d'un outil vs main.
- ☐ Création du protocole expérimental. Ex : Design intrasujet.
- ☐ Création d'une procédure expérimentale. Ex : Mouvement puis estimation.
- ☐ Déterminer une mesure fiable sur le plan psychométrique. Ex : Catégorisation de distances.
- ☐ Test préliminaires du nombre d'essais et type de stimuli. Ex. Stimuli basiques et 200 essais.

Participants

- ☐ Désignation de la population d'intérêt. Ex : Étudiants en STAPS.
- ☐ Taille d'effet attendu et calcul de la puissance statistique. Ex : Test de puissance.

Science ouverte / éthique de recherche

- ☐ Pré-enregistrement OSF. Ex : Template OSF
- ☐ Préparation du consentement éclairé et stockages des données. Ex : Formulaire Nanterre

Collecte de données

- ☐ Attitude neutre de l'expérimentateur. Ex : Script en amont de l'expérimentation.
- ☐ Standardisation de l'expérimentation. Ex : Matériel et espace.

Analyses des données

- ☐ Nettoyages des données. Ex : Erreur de saisie.
- ☐ Check des outliers potentiels. Ex : Résidus + distance de Cook.
- ☐ Choix du test statistique adéquat. Ex : T-test.
- ☐ Check des conditions d'applications du test statistique. Ex : Normalité
- ☐ Report p-value, taille d'effet et intervalle de confiance si possible. Ex : $p = 0.49$, $d = 0.3$.

Discussion

- ☐ Interprétations des résultats fréquentistes ou bayésiens. Ex : Résultat significatif, rejet H_0 .
- ☐ Mise en contexte des résultats au vue de la littérature. Ex : Taille d'effet cohérente.
- ☐ Réponse à l'hypothèse et la problématique de recherche. Ex : Corroboration de l'hypothèse.

Chapitre 1. Crédibilité et qualités psychométriques

Après la crise de la réplication, la crédibilité de la science a été remise en question. Pour y remédier, une réforme a émergé, proposant divers outils pour permettre à la communauté scientifique de progresser de manière plus fiable. Cette réforme prenant plusieurs appellations comme la « renaissance psychologique » (Nelson et al., 2018) ou encore la « révolution de la crédibilité » (Vazire, 2018) s'est penchée sur l'élaboration de guides de recherche améliorant les aspects statistiques, ainsi que sur l'opérationnalisation à travers la conception d'études expérimentales. Dans ce chapitre, nous nous concentrerons plus spécifiquement sur les qualités psychométriques des mesures expérimentales, en abordant notamment les notions de fidélité et de validité. Une mesure fidèle permet d'obtenir des résultats cohérents à travers différentes répétitions d'une même étude, tandis qu'une mesure valide évalue précisément ce qu'elle est censée mesurer. L'exploration et l'amélioration de ces qualités sont donc des étapes importantes pour renforcer la crédibilité et la confiance dans la science.

Chapitre 1.1. Fidélité

Chapitre 1.1.1. Pourquoi la fidélité ?

La crise de la réplication a constitué un défi majeur dans le monde de la science, mettant en lumière la nécessité de répliquer avec succès les résultats des études antérieures. Pour minimiser les échecs de réplication, il est essentiel d'examiner les causes potentielles de ces échecs. En ce sens, Stanley & Spence (2014) suggèrent que certains de ces échecs pourraient être dus à des erreurs de mesure, notamment à une mauvaise fidélité. Une faible fidélité entraînerait une variabilité significative entre les différentes réplifications. Pour illustrer ce point, les auteurs ont mené des milliers de simulations idéales avec les mêmes participants mais en variant certains paramètres pour modéliser la variabilité des réplifications. Ces simulations leur ont permis de formuler des recommandations pour aider les chercheurs à concevoir des études plus rigoureuses avec des attentes plus modérées des chercheurs. Étant donné la variabilité des réplifications, il est insuffisant de s'appuyer sur une seule étude pour conclure sur un objet de recherche. De plus, la fidélité des mesures s'avère être un paramètre clé à surveiller pour améliorer la reproductibilité des études scientifiques et réduire la variabilité des réplifications. En renforçant la fidélité des mesures, les chercheurs peuvent accroître la crédibilité de la science dans son ensemble.




Fig. Simulations de Stanley et Spence (2014)

Chapitre 1.1.2. Quel seuil utilisé ?

En effet, après avoir examiné ces simulations et les graphiques proposés par les auteurs, il est naturel de penser que chaque chercheur devrait utiliser une mesure avec une fidélité aussi élevée que possible. Cependant, atteindre une fidélité parfaite ou proche de la perfection est une tâche complexe, notamment en psychologie où la variabilité humaine est un facteur important. Plutôt que de viser une fidélité parfaite, il serait plus pertinent de se demander à partir de quel seuil une mesure peut être considérée comme acceptable. En psychologie, une fidélité de 0.70 est généralement considérée comme un seuil acceptable pour une mesure. Cependant, il est important de reconnaître que les seuils statistiques et les conventions servent souvent de garde fous sans que l'on en comprenne toujours pleinement la provenance ou l'usage approprié. Historiquement, le seuil de 0.70 provient de l'ouvrage *Psychometric Theory* de Nunnally (1975), où il est mentionné que : “*Reliability theory is not highly important for basic research on individual differences, unless the reliability is miserably low, e.g., below .70*” (pp.10). Cet ouvrage visait à traiter des problèmes de mesure pour les cliniciens et les chercheurs en sciences comportementales comme la psychologie.

Cependant, ce seuil de fidélité a été remis en question par des recherches plus récentes (Lance et al., 2006). Ces auteurs mettent en lumière que le dogme de Nunnally (1978) a été souvent mal interprété, et qu'il n'était pas présenté comme un standard universel dans son ouvrage. En effet, dans la section de son ouvrage *Psychometric Theory*, le seuil de 0.70 n'est pas exposé comme un standard universel et par conséquent n'est pas forcément suffisant pour la recherche ou le domaine médical : *decisions must be made about humans on the basis of test scores, even a reliability of .90 is not high enough* (pp.10). Le problème avec un seuil fixe est qu'il tend à simplifier les questions complexes en une vision binaire, catégorisant une mesure comme acceptable ou non acceptable. Une approche nuancée et réfléchie est essentielle pour garantir que les mesures utilisées sont à la hauteur des exigences de chaque étude. Une autre façon d'évaluer la fidélité d'une mesure consiste à utiliser des intervalles labellisés pour éviter une vision dichotomique. Koo et Li (2016) proposent un guide pour interpréter les coefficients de corrélation intraclasse (ICC), qui regroupent la fidélité test-retest, inter-évaluateurs et intra-évaluateurs. Selon eux, la fidélité peut être qualifiée comme suit : pauvre ($< 0,5$), modérée ($0,5-0,75$), bonne ($0,75-0,9$) et excellente ($>0,9$). Ces catégories offrent une nuance plus riche pour interpréter les résultats.

Dans le domaine de la psychologie cognitive, de nombreuses tâches cognitives sont répliquables, surtout pour les effets les plus notables (e.g., Stroop, SNARC, NAVON), mais elles ne présentent pas nécessairement une fidélité élevée (Hedge, Powell & Sumner, 2017). Les auteurs ont étudié divers effets ainsi que d'autres tâches populaires en psychologie (e.g., Go/NoGo, discrimination, Flanker, etc.). Ils ont mesuré la fidélité à l'aide de l'ICC, qui tient compte de la variabilité intra-individuelle et inter-individuelle. Contrairement aux attentes, l'ICC variait entre 0 et 0,82, ce qui correspondait à des niveaux de fidélité très variable selon les critères de Koo et Li (2016). L'importance réside dans la nécessité d'une fidélité intrasujet élevée pour garantir la répliquabilité de la tâche et l'identification de mécanismes sous-jacents (Wilmer, 2008).

Des chercheurs comme Parsons et al. (2019) proposent une réflexion plus approfondie sur l'interprétation de la fidélité. Ils encouragent les chercheurs à adopter une approche méthodologique plus rigoureuse, centrée sur le calcul et le rapport de la fidélité de chaque mesure utilisée. Ils suggèrent d'effectuer des études spécifiques pour évaluer la fidélité des nouvelles mesures et de partager les données psychométriques dans des archives accessibles à la communauté scientifique. Au-delà des seuils dichotomiques et des intervalles labellisés, les chercheurs devraient comparer l'estimation de leur fidélité avec celle d'autres mesures existantes pour obtenir des conclusions plus nuancées. La fidélité est une qualité psychométrique essentielle d'une mesure, car elle peut influencer de manière significative les résultats obtenus. Les chercheurs doivent être conscients de cette influence potentielle lors de l'interprétation de leurs résultats. Toutefois, la fidélité n'est pas la seule qualité psychométrique à prendre en compte ; d'autres aspects tels que la validité, la sensibilité et la précision doivent également être considérés pour évaluer la robustesse globale d'une mesure.

Chapitre 1.2. Validité

L'engouement pour les études de réplication a émergé en réponse à la crise de la réplication qui a ébranlé la crédibilité de la psychologie en tant que discipline scientifique. Les efforts pour effectuer des réplications visaient à redonner confiance à la communauté scientifique en rétablissant la fiabilité des différents résultats dans la littérature. Cependant, Vazire et al. (2022) soutiennent que les réplications, bien qu'indispensables, ne suffisent pas à elles seules à restaurer la crédibilité perdue. Leur approche met l'accent sur l'importance de la validité sous ses diverses formes. Les auteurs examinent différentes formes de validité (Fitzer, 2007), tout en prenant en compte les avancées réalisées par la communauté scientifique depuis 2011. Ils soulignent la nécessité d'embrasser ces progrès pour orienter la recherche vers une nouvelle doxa, s'appuyant sur une base méthodologique solide afin d'améliorer la validité dans les recherches en psychologie. Ainsi, ils explorent les implications de quatre types de validité : construit, interne, externe et inférentielle.

Chapitre 1.2.1. Validité de construit

La validité de construit (i.e., validité conceptuelle ou théorique) se réfère à l'exactitude avec laquelle une mesure reflète le concept qu'elle est censée évaluer. En d'autres termes, elle pose la question : est-ce que ce que l'on mesure correspond véritablement à ce que l'on veut mesurer ? Il est essentiel de clarifier à la fois le concept d'intérêt et les méthodes d'opérationnalisation utilisées pour étudier ce concept. Un manque de clarté dans ces domaines peut entraîner des inférences invalides et donc remettre en cause la crédibilité des résultats. Par exemple, lorsqu'un chercheur demande à un participant d'estimer une distance, l'interprétation de cette tâche peut varier en raison d'un manque de clarté concernant le concept d'intérêt, comme la perception des distances. Si le concept n'est pas clairement défini pour le chercheur et le participant, il devient difficile de concevoir des mesures opérationnelles qui soient cohérentes avec ce concept. Cependant, certains auteurs utilisant des mesures comportementales pour explorer les processus cognitifs, ne fournissent pas toujours de preuves solides quant à la qualité psychométrique de leurs mesures, qu'il s'agisse de fidélité ou de validité (Parsons et al., 2019). Il est donc crucial d'accorder une attention particulière à la conception expérimentale par le biais d'opérationnalisations cohérentes pour mesurer le construit d'intérêt. En plus de la réflexion sur les concepts et les mesures, divers outils statistiques peuvent être utilisés pour évaluer la validité de construit, tels que l'analyse factorielle ou la convergence des mesures. Ces outils aident à renforcer la qualité des recherches en psychologie en garantissant que les mesures sont précises et alignées sur les concepts étudiés.

Chapitre 1.2.2. Validité interne

La validité interne se réfère à la capacité de tirer des conclusions causales fiables à partir des données recueillies à la suite d'une opérationnalisation. Cette validité examine en particulier les fondements théoriques des hypothèses et des prédictions formulées par le chercheur, posant ainsi la question : les prédictions sont-elles correctement justifiées par les hypothèses, et sont-elles exemptes d'explications

alternatives ? Un manque de validité interne pourrait engendrer des divergences de résultats lors des tentatives de réplification (Wiernik et Dahlke, 2020). Ainsi, la validité interne permet de confirmer que les données observées résultent bien des facteurs d'intérêt et non d'autres variables ou processus. Dans le domaine de la psychologie cognitive, plusieurs menaces à la validité interne peuvent surgir, impliquant l'expérimentateur (e.g., biais de l'expérimentateur) et le participant (e.g., effet Hawthorne, maturation) ou encore l'opérationnalisation (par exemple, caractéristiques de demande). Évaluer la validité interne est toutefois un défi car il n'existe pas d'outil spécifique pour la mesurer. Néanmoins, elle peut être renforcée par un contrôle rigoureux des variables, des méthodes de randomisation et l'application d'autres types de validité.

Chapitre 1.2.3. Validité externe

La validité externe concerne la capacité à généraliser les résultats obtenus à d'autres populations, contextes, et situations. La généralisation grâce à la variation des facteurs expérimentaux, tels que les stimuli, la population ou l'expérimentateur, est souvent négligée. Une des plus grandes menaces à cette validité, qui est plus d'ordre géopolitique que méthodologique, est liée à la population WEIRD. L'acronyme WEIRD (Western, Educated, Industrialized, Rich, Democratic) fait référence principalement aux populations d'Amérique du Nord et d'Europe. Cette population représente une grande majorité des études scientifiques en raison de l'hégémonie des recherches provenant de ces régions, plus de 80% selon Pollet et Saxton (2019). Le problème est que ces études tendent à généraliser leurs conclusions à l'ensemble de la population mondiale, ce qui est souvent inapproprié compte tenu des divergences culturelles et d'autres facteurs contextuels. Une approche prometteuse pour atténuer ce biais consiste à favoriser la recherche participative en collaboration avec des laboratoires provenant de différents pays à travers le monde, comme le fait le Psychological Science Accelerator (Moshontz et al., 2018). Cette démarche favorise une plus grande diversité dans les échantillons et les contextes étudiés, améliorant ainsi la validité externe des recherches en psychologie.




Fig. Pollet et Saxton (2019)

Chapitre 1.2.4. Validité inférentielle

La validité des inférences statistiques se réfère à la crédibilité des conclusions tirées par les chercheurs à partir des données recueillies, ainsi qu'à la rigueur dans le choix des tests et modèles statistiques. Certains chercheurs négligent l'importance de poser des hypothèses claires et justifiées, qui sont pourtant essentielles pour interpréter correctement les résultats statistiques et pour faire des inférences appropriées. Par exemple, dans l'étude de Silberzahn et al. (2018), 29 équipes de chercheurs, regroupant 61 analystes, ont été sollicités pour examiner un jeu de données dans le but de répondre à une question de recherche. Cet exercice a démontré comment les approches analytiques des chercheurs peuvent varier considérablement, même lorsque l'on travaille avec les mêmes données et la même question de recherche. Chaque équipe a suivi une démarche statistique différente, ce qui a mené à des résultats distincts : 20 équipes ont trouvé des résultats statistiquement significatifs, tandis que 9 ont trouvé des résultats non significatifs, avec un intervalle de taille d'effets allant de 0.89 à 2.93 en odds ratio. Cet exemple illustre que les hypothèses de départ, formulées en fonction du cadre théorique, influencent grandement les choix statistiques et donc les résultats finaux. En outre, Scheel et al. (2020) ont souligné que malgré le fait que les tests d'hypothèses soient courants en psychologie, ils sont souvent menés sans des concepts clairs ou des prédictions statistiques précises. Ces prédictions statistiques peuvent inclure, par exemple, une taille d'effet minimale à atteindre. En résumé, la validité des inférences statistiques nécessite de définir des hypothèses préalables solides et justifiées, ainsi que d'adopter des méthodes statistiques appropriées. Cela garantit que les conclusions tirées des données sont fiables et reflètent fidèlement la réalité étudiée.

Les différents types de validités donnent des pistes de réflexions et des outils pour le cheminement scientifique et un regard critique sur ce que chacun fait et ce qui a été fait par autrui.

Chapitre 2. Méthodologie

Chapitre 2.1 Design et puissance

Chapitre 2.1.1. Définition et compréhension

Qu'est-ce que la puissance statistique ? Baguley (2004) définit la puissance statistique d'un test d'hypothèse nulle comme « *la probabilité que ce test signale un effet statistiquement significatif pour un effet réel d'une ampleur donnée* » (pp. 74). En termes plus simples, cela revient à se demander : si un effet existe avec une certaine taille, quelle est la probabilité de le détecter ? Pour les adeptes des statistiques, cela correspond à la probabilité d'éviter une erreur de type II. L'objectif pratique derrière ce concept est de maximiser la puissance statistique pour qu'une étude puisse révéler l'existence de l'effet d'intérêt. Inversement, si la puissance statistique est trop basse, le test risque de ne pas détecter cet effet.

Pour calculer la puissance statistique, une multitude d'outils et de logiciels sont disponibles, chacun avec ses spécificités (Lakens et Caldwell, 2021). Par exemple, l'un des outils les plus connus et accessibles, avec des fonctionnalités intéressantes, est G*Power 3 (Faul et al., 2007 ; Faul et al., 2009). G*Power permet aux chercheurs de déterminer la taille de l'échantillon nécessaire pour atteindre une puissance statistique adéquate, ainsi que d'effectuer diverses analyses de puissance pour différents types de tests statistiques.

L'objectif est donc d'obtenir une puissance statistique s'approchant le plus possible de 100% pour assurer qu'un test statistique puisse détecter un effet avec certitude. Toutefois, atteindre une puissance statistique de 100% est rarement réaliste, car cela nécessite un nombre très élevé de participants et des ressources importantes. En pratique, il n'est pas nécessaire d'avoir une puissance aussi élevée. Dans son ouvrage sur la puissance statistique, Cohen (1988) propose comme convention 80% comme puissance statistique acceptable, en tenant compte des considérations théoriques et pratiques. Ce seuil, bien que largement utilisé, reste arbitraire, il peut être recommandé d'atteindre une puissance statistique de 95% pour plus de rigueur.

Chapitre 2.1.2. Quel est le problème ?

Les difficultés à répliquer les résultats présents dans la littérature reflètent un problème inhérent à de nombreux domaines de recherche en psychologie : la méthodologie utilisée. Bien que complexe et englobant une multitude de concepts, la méthodologie est essentielle pour assurer une démarche scientifique fiable. Un des problèmes récurrents constatés dans la littérature

depuis plusieurs décennies est la faible puissance statistique, observée dans les domaines médicaux, des neurosciences et, en particulier, en psychologie (Szucs et Ioannidis, 2017).

Les auteurs ont évalué les puissances statistiques en fonction des tailles d'effet dans ces trois domaines, en incluant des articles provenant de différentes revues scientifiques. Un résultat notable pour la psychologie montre que, respectivement pour des tailles d'effet faible, moyenne et forte, la puissance statistique moyenne pour détecter l'effet était de 0.23, 0.60 et 0.78. Plus la taille d'effet est faible, plus il est difficile d'atteindre une puissance statistique suffisante pour détecter cet effet, ce qui explique les valeurs observées. Ces valeurs de puissance statistique indiquent que, peu importe la taille de l'effet, la puissance statistique est globalement insuffisante (i.e., $< 0,80$).

De plus, les articles analysés dataient de janvier 2011 à août 2014, soit après la crise de la réplication et les répercussions méthodologiques qui ont suivi. Cela indique que, même après cette crise, la puissance statistique, un concept pourtant fondamental, n'a pas été respectée de manière adéquate. Cette situation souligne la nécessité de renforcer les pratiques méthodologiques dans la recherche en psychologie pour améliorer la reproductibilité et la fiabilité des résultats.

Subfields or other surveys	Records/Articles	Small effect		Medium effect		Large effect	
		Median	Mean	Median	Mean	Median	Mean
Cognitive neuroscience	7,888/1,192	0.11	0.14	0.40	0.44	0.70	0.67
Psychology	16,887/2,261	0.16	0.23	0.60	0.60	0.81	0.78
Medical	2,066/348	0.15	0.23	0.59	0.57	0.80	0.77
All subfields	26,841/3,801	0.11	0.17	0.44	0.49	0.73	0.71

Fig. Szucs et Ioannidis, 2017

Chapitre 2.1.3. Comment améliorer sa puissance ?

La puissance statistique, calculée à partir de formules spécifiques selon le type de test statistique et la taille d'effet utilisée, est influencée par trois facteurs principaux : la taille d'effet attendue, la taille de l'échantillon et le plan expérimental. Les plans expérimentaux peuvent être divisés en deux grandes catégories : intrasujet et intergroupe. Dans les plans intrasujet, chaque participant est exposé à toutes les modalités de la variable d'intérêt, contrairement aux plans intergroupes où chaque participant est exposé à une seule modalité. En plus de gérer la variabilité interindividuelle et de fournir une meilleure visibilité sur l'expérimentation, ces plans expérimentaux diffèrent également en termes de nombre de participants requis (Charness et al., 2012). Les plans intrasujet ont l'avantage de nécessiter moins de participants que les plans intergroupes.





Fig. Intra vs Inter

Cependant, Meyvis et Van Osselaer (2018) proposent comme alternative d'augmenter la taille de l'effet. Lors du calcul d'un test de puissance statistique, une taille d'effet plus grande se traduit par une puissance statistique plus élevée. Par conséquent, combiner l'augmentation de la taille de l'effet avec celle de l'échantillon pourrait constituer une double stratégie pour améliorer la puissance statistique. Les auteurs suggèrent plusieurs pistes d'amélioration, notamment la suppression judicieuse des participants (voir section outliers) et l'optimisation du dispositif expérimental.

Bien que théoriquement simple, augmenter la taille de l'échantillon est souvent plus compliqué en pratique. Une option intéressante pour des études nécessitant plusieurs centaines de participants serait l'analyse séquentielle (Lakens, 2014). L'analyse séquentielle divise

l'expérimentation en plusieurs phases et réalise des analyses intermédiaires. À chaque étape, des seuils prédéfinis déterminent s'il est nécessaire de continuer ou d'arrêter l'expérience. L'objectif est de pouvoir arrêter l'expérimentation dès que possible afin d'économiser du temps et des ressources humaines. Pour ce type de pratique, il est vivement recommandé de préenregistrer l'étude, garantissant ainsi une transparence totale.

Comme nous avons pu le constater, la puissance statistique est devenue un concept central depuis la crise de la réplication. Cette notion a été l'une des principales critiques méthodologiques dans le domaine de la recherche. Plus généralement, la puissance statistique est désormais un critère essentiel pour la publication dans de nombreuses revues scientifiques, qui exigent des études ayant une puissance statistique suffisante, souvent atteinte par une taille d'échantillon importante. Les études menées avec de grands échantillons sont considérées comme plus fiables pour les inférences scientifiques que celles avec de petits échantillons. Cependant, Smith et Little (2018) proposent une argumentation en faveur des petits échantillons. Ils soutiennent que les petits échantillons, voire des études de cas uniques, peuvent avoir un pouvoir inférentiel comparable, voire supérieur, à celui des grands échantillons. Les petits échantillons et les grands échantillons ne représentent que des extrêmes d'un large continuum du concept de taille d'échantillon. Selon eux, le problème ne réside pas dans la taille de l'échantillon, mais dans les mesures utilisées, le contrôle de la variabilité et les modèles théoriques appliqués. Ces facteurs indirects ont été occultés dans cette réforme, car la psychologie utilise les inférences statistiques de manière dépendante pour faire de la science. Et c'est donc sur les inférences statistiques et ces facteurs directs pouvant l'influencer que les chercheurs ont priorisé (e.g., significativité). L'objectif est alors d'obtenir des résultats significatifs grandement aidés par des tailles d'échantillons conséquents.

Chapitre 2.1.4. Que choisir comme taille d'effet ?

Cependant, bien que nous discutons du calcul de la puissance statistique en fonction d'une certaine taille d'effet, comment déterminer quelle taille d'effet utiliser ? Lorsque la taille d'effet est connue, il suffit de se référer à l'étude princeps dans le cadre d'une réplication, qu'elle soit directe ou par extension, ou dans le meilleur des cas, à une méta-analyse du champ de recherche qui propose une taille d'effet médiane (Cohen, 1988). Il arrive que les tailles d'effet reportées dans certains articles diffèrent de celles présentes dans les logiciels. Dans ce cas, il est possible de convertir une taille d'effet en une autre par une simple conversion mathématique (voir Borenstein, 2009).

Cependant, il peut arriver que la taille d'effet attendue soit inconnue. Une approche possible est d'estimer la plus petite taille d'effet d'intérêt (Lakens et al., 2018) pour calculer une taille d'échantillon minimale nécessaire afin d'obtenir une puissance statistique satisfaisante. La plus petite taille d'effet d'intérêt correspond à la taille d'effet minimale que le chercheur suppose a priori, basée sur des effets déjà observés dans la littérature. Pour les études exploratoires, il est plus compliqué de déterminer une taille d'effet minimale. Dans ces cas, il est utile de se fier aux tailles d'effet présentes dans le domaine de recherche concerné ou, à défaut, dans la discipline scientifique globale à laquelle l'étude appartient.

Pour publier, il est recommandé de réaliser un test de puissance justifiant la taille d'échantillon afin d'assurer une rigueur méthodologique. Lakens (2022) propose un guide pratique pour les chercheurs désirant justifier leur taille d'échantillon, en prenant en compte divers facteurs au-delà du simple test de puissance (e.g., type d'étude, design, etc.). Cependant, il est important de noter qu'une grande puissance statistique ne garantit pas une inférence causale solide à partir des données. Comme le soulignent Wagenmakers et al. (2015), une étude avec une grande puissance statistique peut parfois être trompeuse. Il est donc recommandé d'utiliser des outils bayésiens, tels que les rapports de vraisemblance ou les Bayes Factor, pour compléter et renforcer les inférences causales.

Chapitre 2.2 Taille d'effet

La taille d'effet est un concept central dans les statistiques fréquentistes et a souvent été incomprise ou non utilisée par la plupart des chercheurs. Cette incompréhension générale est due à la pluralité des définitions proposées pour ce concept. Kelley, Preacher (2012) ont ainsi défini la taille d'effet comme : « une statistique (ou paramètre) qui a pour but de quantifier un phénomène qui répond à une question d'intérêt » [...] « Un reflet quantitatif de l'ampleur d'un phénomène qui est utilisée dans le but de répondre à une question d'intérêt » (pp. 140). Cette définition se veut inclusive afin d'incorporer une logique de pensée unificatrice derrière la pluralité des définitions et utilisations (Kirk 1996 ; Grissom and Kim (2005, 2012) ; Ellis, 2010, Rosenthal, 1994 ; Vacha-Haase and Thompson, 2004 ; Cohen, 1988).

Chapitre 2.2.1. Caractéristiques tailles d'effet

Avec cette définition, les auteurs définissent également trois facettes caractérisant la taille d'effet. Tout d'abord, la dimension de la taille d'effet renvoie à la nature de l'information d'intérêt. La dimension d'une taille d'effet est une abstraction d'une caractéristique pouvant être quantifiée de manière générale, mais n'ayant pas d'unité particulière. Un exemple proposé par les auteurs est la variabilité, qui peut être quantifiée par des unités telles que des paramètres de dispersion (e.g., la variance, l'écart-type). Ensuite, la mesure ou l'indice de la taille d'effet renvoie à l'opérationnalisation de la taille d'effet à l'aide de formules, de données, de statistiques ou de paramètres. Ceci permet d'exprimer la dimension d'intérêt à travers une formule mathématique. L'un des exemples les plus connus est le d de Cohen, qui représente une différence de moyenne standardisée. Cette formule est donc l'opérationnalisation de la dimension d'une différence entre les moyennes de deux groupes. Enfin, la valeur de la taille d'effet renvoie à l'interprétation théorique. La valeur de la taille d'effet est la finalité statistique caractérisée par une valeur numérique. Cette valeur représente la magnitude d'un phénomène d'intérêt. En résumé, la valeur de la taille d'effet est le résultat de l'opérationnalisation de la dimension d'intérêt de la taille d'effet par l'intermédiaire d'une mesure ou d'un indice.

Les applications et implications sont nombreuses, et plus complexes que ce que l'on peut penser. Dans une discussion autour de la taille d'effet, Preacher et Kelley (2011) propose comment reconnaître « une bonne taille d'effet » avec 4 propriétés.

1. Les valeurs de taille d'effet doivent être adaptées correctement, avec la mesure et la question d'intérêt.
2. Les valeurs de taille d'effet devraient être accompagnées d'intervalles de confiances.

3. L'estimation ponctuelle de la valeur de la taille d'effet sur la population doit être indépendante de la taille de l'échantillon.
4. Les estimations des valeurs de taille d'effet doivent posséder des propriétés d'estimations souhaitables : sans biais (égales à la population), cohérents (convergence vers la valeur de la population) et efficaces (variance minimale).

Chapitre 2.2.2. Revue des tailles d'effets

Maintenant que la notion de taille d'effet a été définie, la question qui se pose est : quelle taille d'effet utiliser et comment la calculer, interpréter et rapporter ? Lakens (2013) propose une revue des différentes mesures de taille d'effet pour les t-tests et les ANOVAs. Pour chaque mesure de taille d'effet, Lakens donne une formule mathématique pour les calculer, une méthode de standardisation, ainsi qu'une recommandation sur leur utilisation appropriée. L'objectif de cet article est de promouvoir une culture commune autour de la taille d'effet afin de faciliter la recherche cumulative. En utilisant les mêmes outils statistiques de manière claire et précise, il est alors plus simple de progresser ensemble dans la recherche.

ES	Standardizer	Use
Cohen's d_{pop}	σ (population)	Independent groups, use in power analyses when population σ is known, σ calculated with n
Cohen's d_s	Pooled SD	Independent groups, use in power analyses when population σ is unknown, σ calculated with $n-1$
Hedges' g	Pooled SD	Independent groups, corrects for bias in small samples, report for use in meta-analyses
Glass's Δ	SD pre measurement or control condition	Independent groups, use when experimental manipulation might affect the SD
Hedges' g_{av}	$(SD_1 + SD_2)/2$	Correlated groups, report for use in meta-analyses (generally recommended over Hedges' g_{rm})
Hedges' g_{rm}	SD difference scores corrected for correlation	Correlated groups, report for use in meta-analyses (more conservative than Hedges' g_{av})
Cohen's d_z	SD difference scores	Correlated groups, use in power analyses

ES (Biased)	ES (Less Biased)	Use
eta squared (μ^2)	omega squared (ω^2)	Use for comparisons of effects within a single study
eta squared (μ_p^2)	omega squared (ω_p^2)	Use in power analyses, and for comparisons of effect sizes across studies with the same experimental design.
Generalized eta squared (μ_G^2)	Generalized omega squared (ω_G^2)	Use in meta-analyses to compare across experimental designs

Fig. Taille d'effet de Lakens (2013)

Pour calculer une taille d'effet, il est conseillé d'utiliser un logiciel pouvant le faire plutôt que d'utiliser directement les formules (i.e., plus efficient). Plusieurs logiciels existent apportant ses spécificités, mais la totalité fera l'affaire. Que ce soit payant (SPSS, Statistica), gratuit (JASP, Jamovi) ou avec du code (R, Matlab, Python), aucun logiciel n'est préférentiel pour réaliser un calcul de taille d'effet.




Fig. Exemple Jamovi

Chapitre 2.2.3. Simples vs standardisées

Dans les différentes mesures de taille d'effet, on distingue principalement deux types : les tailles d'effet simples et les tailles d'effet standardisées. Prenons un exemple pour mieux les comprendre dans un contexte de recherche médicale sur deux médicaments destinés à

augmenter le nombre de globules blancs. Les chercheurs répartissent les deux médicaments entre deux groupes de 50 individus chacun : le médicament A pour le groupe A et le médicament B pour le groupe B. Les niveaux de globules blancs sont mesurés avant et après la prise des médicaments pour observer d'éventuels changements. Après analyse, les chercheurs obtiennent les résultats suivants : le médicament A entraîne une augmentation moyenne de 10M de globules blancs, tandis que le médicament B entraîne une augmentation de 9M (avec un écart type de 2.5M pour chacun).

Dans ce cas, il est possible de calculer une taille d'effet simple, qui est la différence entre les deux moyennes, soit 1M. Mais on peut également calculer une taille d'effet standardisée selon une formule mathématique ou à l'aide d'un logiciel, donnant un $d = 0.4$. La taille d'effet simple est ainsi très concrète et directement liée au contexte de l'étude, qui est ici les globules blancs et la médication. En revanche, la taille d'effet standardisée est plus abstraite et permet une comparaison plus aisée avec d'autres recherches qui n'ont pas le même contexte d'étude.

Mais quelle est la meilleure option ? Baguley (2009) propose de répondre à cette question. L'auteur suggère que la standardisation, bien que très intéressante pour réaliser des comparaisons, peut biaiser la taille d'effet initiale en fonction de certains facteurs comme les plans expérimentaux ou la fidélité. Il est donc nécessaire d'effectuer des corrections. Pour mieux choisir entre taille d'effet simple et standardisée, l'auteur élabore un guide pour rapporter les effets. Globalement, il est préférable d'utiliser une taille d'effet simple, de réaliser des intervalles de confiance en plus des estimateurs ponctuels, et de corriger les tailles d'effet standardisées.

Chapitre 2.2.4. Interprétations

Maintenant que nous avons réussi à comprendre la notion de taille d'effet, il est nécessaire de pouvoir l'interpréter. Dans son ouvrage ayant fait référence dans le monde statistique, Cohen (1988) a proposé des conventions générales afin d'interpréter les tailles d'effets selon le d de Cohen ou le r de Pearson :

d de Cohen	r de Pearson	Interprétation
$d < 0.20$	$r < 0.1$	Très petit
$d \geq 0.20$	$0.1 < r < 0.3$	Petit

$d \geq 0.50$	$0.3 < r < 0.5$	Moyen
$d \geq 0.80$	$r \geq 0.5$	Grand

Les tailles d'effets étant fortement reliées entre elles, il est possible de les convertir entre elles (e.g., $d \rightarrow r$, Ruscio, 2008, note bas de page). Ces conventions étant arbitraires, Cohen proposait de réaliser une méta-analyse dans le champ de recherche afin d'estimer une taille d'effet générale et sa distribution afin de mieux interpréter la taille d'effet. Funder et Ozer (2019) ont réalisé une réactualisation des conventions de Cohen, dans le domaine de la psychologie expérimentale avec une taille d'effet r de Pearson :

Taille d'effet	Interprétation psychologie expérimentale
$r \geq 0,05$	Effet très faible pour l'explication d'événements uniques, mais potentiellement conséquents à court terme
$r \geq 0,10$	Effet encore faible au niveau d'événements isolés, mais potentiellement plus conséquents
$r \geq 0,20$	Effet moyen, qui est d'une certaine explication et une utilisation pratique à court terme voire moyen/long terme
$r \geq 0,30$	Effet grand, potentiellement puissant à court et à long terme
$r \geq 0,40$	Effet très grand et susceptible d'être une surestimation grossière qui sera rarement trouvé dans un grand échantillon ou dans une réplication.

Chapitre 2.2.5. Cas des effets nuls

Une distinction pertinente concerne l'interprétation des effets nuls lors des tests statistiques portant sur la moyenne. Lorsqu'un expérimentateur obtient un résultat nul, deux interprétations différentes sont possibles (Miller et Schwarz, 2018). La première interprétation suggère que

l'expérimentation est inefficace et qu'aucun effet n'est observé chez les participants. La deuxième interprétation propose que l'expérimentation soit efficace en produisant un effet dans une direction donnée, mais opposée pour un certain nombre de participants. Bien que ces deux interprétations soient diamétralement opposées, elles conduisent cependant au même résultat. La différence réside dans les variations interindividuelles qui peuvent masquer un effet potentiel. Lorsqu'un effet nul est constaté, il semble donc intéressant de regarder plus en détail les participants pour possiblement détecter des profils ou des éléments permettant de les rassembler afin de mieux comprendre les résultats obtenus.

De plus, lorsqu'une étude produit un effet considéré comme nul ou quasi nul, il est vivement recommandé d'utiliser une approche complémentaire, telle que l'approche bayésienne avec le Bayes Factor, pour fournir des preuves de la tendance des données (Dienes, 2014 ; Lakens et al., 2020). En plus de l'approche bayésienne, des outils statistiques fréquentistes, tels que les tests d'équivalence (Lakens, 2017 ; Lakens et al., 2018), peuvent également être utilisés. Alors que certaines méthodes permettent de tester l'existence d'un effet, les tests d'équivalence permettent de vérifier l'absence d'un effet.

Chapitre 2.2.6. Constats généraux

Une revue de littérature très pertinente a exploré les tailles d'effets à travers le prisme des préenregistrements dans diverses disciplines scientifiques (Schäfer et Schwarz, 2019). Cette revue systématique a porté sur neuf sous-disciplines de la psychologie (appliquée, biologique, clinique, développementale, éducative, expérimentale, multidisciplinaire, psychanalytique, sociale) à travers l'examen de 90 journaux scientifiques, couvrant une période allant de 1912 à 2017 et regroupant 773 effets empiriques. Les auteurs ont ainsi pu classer ces études selon les sous-disciplines, les designs expérimentaux utilisés et l'utilisation ou non de préenregistrements. Les résultats obtenus sont particulièrement instructifs.

Design : Le premier résultat intéressant est que globalement le nombre d'études utilisant un design intrasujet ou intergroupes étaient globalement similaires, mais que les tailles d'effets différaient. En effet, pour les designs intrasujet, les tailles d'effets étaient systématiquement plus grandes que les designs intergroupes que ce soit pour les petits, moyens et larges effets.

Descriptor	Studies without pre-registration			Studies with pre-registration		
	Total	Between-subjects designs	Within-subject designs	Total	Between-subjects designs	Within-subject designs
<i>N</i>	684	313	358	89	63	26
<i>M</i>	0.40	0.37	0.42	0.21	0.17	0.33
<i>SD</i>	0.21	0.20	0.22	0.19	0.15	0.22
Lower <i>Mdn</i> ($\approx$ small effect)	0.20	0.18	0.21	0.04	0.04	0.09
Grand <i>Mdn</i> ($\approx$ medium effect)	0.36	0.34	0.38	0.16	0.12	0.31
Upper <i>Mdn</i> ($\approx$ large effect)	0.62	0.57	0.67	0.41	0.30	0.56

Fig. Schäfer et Schwarz, 2019

Sous discipline : Le deuxième résultat intéressant concernant les sous-disciplines est que la taille d'effet médiane allait de $r = 0.3$ pour la sociale, jusqu'à 0.5 pour la biologique, avec une médiane globale de 0.36. Ce qui est intéressant est de pouvoir comparer ces résultats avec les conventions de Funder et Ozer (2019), signifiant que la plupart des effets peuvent être anormalement grands. Cela reflèterait une surestimation des effets de manière générale à la discipline de psychologie.




Fig. Schäfer et Schwarz, 2019

Préenregistrement : Le troisième résultat intéressant concerne la différenciation par préenregistrement. Les auteurs ont comparé les tailles d'effets (i.e., r) avec les conventions de Cohen (1988) : $r = 0.1$ petit effet, $r = 0.3$ moyen effet, $r = 0.5$ grand effet. Les tailles d'effets avec préenregistrement étaient systématiquement en dessous des conventions alors que les tailles d'effets sans préenregistrement étaient systématiquement au-dessus. Ce résultat pourrait être révélateur de biais introduit par les expérimentateurs qui augmenteraient artificiellement les tailles d'effets. À noter une disparité quantitative importante entre les études avec préenregistrement ($n = 89$) et sans préenregistrement ($n = 684$)




Fig. Schäfer et Schwarz, 2019

Taille d'échantillon : Le quatrième résultat fait le lien entre les tailles d'effets et les tailles d'échantillons. Que ce soit pour les études avec préenregistrement ($r = -0.22$) ou sans préenregistrement ($r = -0.46$), la corrélation était négative. Autrement dit, plus les tailles d'effets sont petites, plus les tailles d'échantillons sont grandes. L'interprétation des auteurs, est que les grosses tailles d'échantillons permettent de rendre statistiquement significative n'importe quelle ampleur de taille d'effet ce qui la rend publiable et donc cela relèverait d'un biais de publication évident.




Fig. Schäfer et Schwarz, 2019

Cette revue systématique offre une vue d'ensemble de la psychologie concernant les tailles d'effet à travers différents paramètres. Une conclusion clé est que le nombre de préenregistrements reste encore insuffisant. Les designs intrasujet semblent détecter des effets plus importants, ce qui pourrait faciliter la détection des effets. Dans l'ensemble, les tailles d'effet demeurent souvent surestimées, ce qui pourrait être attribuable en partie aux études non

préenregistrées. Ces constats contribuent à une meilleure compréhension des résultats obtenus dans les études psychologiques.

Chapitre 2.3 Intervalles de confiance

La notion d'intervalle de confiance est familière à la plupart des personnes, car elle est généralement abordée dans les cours de statistiques dispensés dans l'enseignement supérieur. Cependant, cette notion est souvent mal comprise par les étudiants, voire par les chercheurs qui l'utilisent régulièrement. Hoekstra et al. (2014) ont mené une étude où ils ont soumis un questionnaire à des chercheurs ($n = 118$) ainsi qu'à des étudiants de première année ($n = 442$) et de master ($n = 34$), totalisant ainsi un échantillon de 562 participants. Chaque participant devait répondre vrai ou faux à six affirmations concernant une situation fictive où un professeur réalise une expérience et rapporte un intervalle de confiance à 95 % pour une moyenne comprise entre 0,1 et 0,4. Toutes les affirmations étaient fausses, mais seuls 11 participants ont répondu correctement. Il est donc évident que cette notion est largement mal comprise, aussi bien parmi les étudiants que parmi les chercheurs, alors même qu'elle est couramment utilisée, ce qui soulève des problèmes d'interprétation dans les études. La définition exacte d'un intervalle de confiance est la suivante : « Si nous répétons l'expérience à plusieurs reprises, les intervalles de confiance contiendraient la véritable moyenne dans 95 % des cas » (pp. 1960). Afin de mieux comprendre les intervalles de confiance, une solution pourrait consister à utiliser des indicateurs graphiques tels que les barres d'erreur pour communiquer des informations inférentielles plus claires (Cumming et Finch, 2005 ; Cumming, Williams et Fidler, 2004).

Table 1 Percentages of students and teachers endorsing an item

Statement	First Years ($n = 442$)	Master Students ($n = 34$)	Researchers ($n = 118$)
<i>The probability that the true mean is greater than 0 is at least 95 %</i>	51 %	32 %	38 %
<i>The probability that the true mean equals 0 is smaller than 5 %</i>	55 %	44 %	47 %
<i>The "null hypothesis" that the true mean equals 0 is likely to be incorrect</i>	73 %	68 %	86 %
<i>There is a 95 % probability that the true mean lies between 0.1 and 0.4</i>	58 %	50 %	59 %
<i>We can be 95 % confident that the true mean lies between 0.1 and 0.4</i>	49 %	50 %	55 %
<i>If we were to repeat the experiment over and over, then 95 % of the time the true mean falls between 0.1 and 0.4</i>	66 %	79 %	58 %

Chapitre 2.4. Réplication

Chapitre 2.4.1. Définition

Dans le domaine scientifique, la réplication est courante pour vérifier la validité d'un concept. Il est important de distinguer les concepts de réplication, de reproductibilité et de robustesse, bien que ces termes soient souvent utilisés de manière interchangeable. Selon Nosek et al., (2022), ces trois notions ont des nuances et des implications différentes

La reproductibilité consiste à évaluer la fiabilité des résultats issus d'études antérieures en utilisant les mêmes données et la même stratégie d'analyse. Cette démarche permet de vérifier qu'aucune erreur statistique n'a été commise par les auteurs. Bien que cela puisse sembler basique, c'est un aspect crucial pour garantir la crédibilité des résultats et des inférences causales des chercheurs. Avec l'avènement de la science ouverte et de la transparence des chercheurs, qui partagent leurs données brutes (e.g., OSF), la reproductibilité devient plus facile à vérifier.

La robustesse, quant à elle, teste la fiabilité d'un résultat obtenu dans une étude antérieure en utilisant les mêmes données, mais une stratégie d'analyse différente. Elle est liée à la validité des inférences statistiques des chercheurs. Diverses analyses statistiques peuvent produire des résultats différents, même pour une question de recherche identique (Silberzahn et al., 2016). L'approche idéale pour évaluer la robustesse serait d'utiliser une analyse multivers, explorant toutes les analyses statistiques plausibles pour une même hypothèse ou question de recherche (Steege, 2016). Une forte robustesse est indiquée par une faible divergence dans les résultats obtenus à travers plusieurs analyses statistiques.

La réplicabilité teste la fiabilité d'un résultat provenant d'une étude antérieure en utilisant de nouvelles données. Cette méthode a été critiquée pour son manque d'innovation et d'originalité, mais la crise de la réplication, où de nombreuses études ont échoué à être répliquées, a ravivé l'intérêt pour cette pratique. Les réplifications améliorent la fiabilité des connaissances scientifiques en psychologie (Kooze et Lakens, 2012). Cela souligne l'importance de répliquer les études, y compris celles portant sur les contraintes des actions, pour assurer la solidité des résultats obtenus.

Chapitre 2.4.2. Réussite ou échec ?

Avant tout chose, il est important de définir clairement ce qu'est un « échec de réplication ». Nelson et al. (2018) proposent deux approches pour déterminer si une réplication peut être considérée comme un échec ou simplement un succès relatif. La méthode la plus courante

repose sur la significativité statistique comme critère de jugement. Autrement dit, une étude est considérée comme un échec de réplication si l'effet d'intérêt n'est pas statistiquement significatif. Cependant, un résultat non significatif peut être dû à une faiblesse méthodologique comme le manque de puissance statistique plutôt qu'à une réelle absence d'effet (voir la section sur la puissance statistique). Un autre problème se pose même lorsque les résultats sont statistiquement significatifs : les tailles d'effet peuvent varier considérablement. Par exemple, dans le cas d'une étude fictive présentant une taille d'effet significative élevée (e.g., $d = 0.80$) avec 20 participants, et une réplication avec une taille d'effet significative très faible (e.g., $d = 0.01$) avec 20 millions de participants, il serait inapproprié de considérer la réplication comme réussie avec la significativité statistique, car les tailles d'effet diffèrent considérablement. Une approche alternative consiste à rechercher une différence statistiquement significative entre les tailles d'effet des deux études pour déterminer un échec de réplication. Toutefois, cette approche peut être problématique dans le cas d'études avec une grande puissance statistique ou de grands échantillons, surtout lorsque les tailles d'effet sont proches du seuil de significativité (i.e., $p = 0.05$). Par exemple, il est possible de trouver une différence statistique significative entre une taille d'effet de 0,50 et une autre de 0.49 avec de grands échantillons, mais en réalité, cette différence est négligeable. Une solution serait d'utiliser des intervalles de confiance ou de crédibilité pour évaluer la taille d'effet observée dans l'étude principale. Si la taille d'effet de la réplication se situe en dehors de cet intervalle, on pourrait considérer qu'il y a échec de réplication (Patil et al., 2016). Les échecs de réplication doivent être évalués avec prudence et en tenant compte des outils statistiques disponibles. Enfin, les auteurs recommandent de considérer les différences de tailles d'effet pour déterminer à quel point une taille d'effet est suffisamment plus petite ou plus grande. Une approche bayésienne pourrait également être utilisée pour évaluer la cohérence des données de la réplication par rapport à celles de l'étude principale.

Chapitre 2.4.3. Implications

Maintenant que les critères permettant de déterminer le succès ou l'échec d'une réplication sont établis, il est intéressant de discuter des implications des résultats de réplication. Tout d'abord, il est important de distinguer les différents types de réplication (Schmidt, 2009). La réplication directe consiste à reproduire une étude en utilisant les mêmes procédures et dispositifs que l'étude originale. Son objectif est de confirmer les résultats antérieurs en obtenant un ensemble de données similaire à celui de l'étude d'origine.

La réplication conceptuelle, quant à elle, vise à tester le même concept théorique en employant une opérationnalisation différente. L'objectif est de valider les prédictions théoriques des chercheurs en utilisant des méthodes alternatives. Ces deux types de réplifications mettent en lumière des aspects différents de la recherche, avec des implications variant en fonction du résultat et du type de réplication (Crandall et Sherman, 2016).

Un succès de réplication directe renforce la crédibilité de la méthode utilisée, mais n'apporte qu'un soutien limité à la théorie sous-jacente. En revanche, un succès de réplication conceptuelle confère une plus grande validité à la fois aux méthodes alternatives employées et aux interprétations théoriques, renforçant ainsi l'ensemble du champ de recherche. En cas d'échec de réplication directe, des doutes peuvent être émis sur la méthode d'origine, ce qui fragilise les preuves théoriques associées à l'étude initiale. Pour un échec de réplication conceptuelle, il est important d'examiner attentivement la méthode de réplication utilisée et de considérer des explications alternatives pour les résultats originaux, ce qui affaiblit globalement les preuves théoriques associées.

Le domaine de recherche des contraintes des actions a subi plusieurs échecs de réplifications sur différents niveaux, il est donc important de convenir dans un premier temps si l'échec de réplication est justifié et dans un second temps, les implications qui en découlent.

Table 1

The value of exact and conceptual replications: Success and failure.

Kind of replication	Replication "Succeeds"	Replication "Fails"
Exact	- Increases confidence in methods of previous study - Theoretical reach unaffected - Confidence in theory modestly improved	- Methods of first study come under some suspicion - Original support for theory weakened
Conceptual	- Increases confidence in reach of theory - Supports <i>theoretical</i> interpretation of previous study - Methods of both studies earn confidence	- Focus on methods of replication - Support for theory diminishes - Alternative explanations for previous study considered

Fig. Crandall et Sherman (2016)

Chapitre 3. Tests statistiques

Chapitre 3.1 NHST

Chapitre 3.1.1. Historique

Avant de décrire les pratiques des NHST, il est intéressant de faire un aparté épistémologique, sur la création des NHST qui est en soi une incohérence idéologique (Perezgonzalez, 2015). Les NHST sont une approche hybride entre deux approches statistiques : l'approche de Fisher et celle de Neyman-Pearson.

L'approche de Fisher :

1. La sélection du test statistique approprié. En effet, selon les différences que l'on souhaite observer et notamment sur la nature des variables, il est nécessaire d'utiliser des tests statistiques appropriés.
2. La sélection de l'hypothèse nulle (H_0). L'hypothèse nulle découle logiquement du test statistique et des groupes ou variables d'intérêt, sous la forme d'une hypothèse statistique (e.g., $H_0 : M_1 - M_2 = 0$). Une particularité est que dans certains cas H_0 n'est pas forcément une hypothèse nulle équivalente à 0, mais plutôt une différence qui n'excède pas une valeur seuil prédéterminée.
3. Calcul de la probabilité théorique des résultats sous H_0 (i.e., *p-value*). Cette *p-value* correspond à la probabilité des résultats observés ainsi que de tout autre résultat plus extrême, alors que l'hypothèse nulle est considérée comme vraie.
4. Évaluer la significativité statistique des résultats. Si la *p-value* se trouve au-dessus du seuil de significativité (e.g., 0.05), elle est considérée comme statistiquement non significative. Alors que si la *p-value* se trouve en dessous ou égal le seuil de significativité, elle est considérée comme statistiquement significative.
5. Interpréter la significativité des résultats. Cette *p-value* peut s'interpréter de deux façons différentes. Soit un résultat rare vient de se produire selon la probabilité énoncée, soit H_0 n'explique pas correctement les résultats.

Avec cette approche, l'hypothèse alternative n'est pas spécifiée, ce qui représente une des principales critiques. De plus, la puissance statistique n'est pas prise en compte.

L'approche de Neyman-Pearson

A priori

1. Fixer la taille d'effet attendu dans la population. Le concept de taille d'effet a été introduit par cette approche et se réfère classiquement à l'ampleur de la différence entre deux conditions ou groupes.
2. Sélection du test optimal. Cette approche met en avant la puissance des tests statistiques et que certains tests sont plus puissants que d'autres (e.g., tests paramétriques > non paramétriques).
3. Fixer l'hypothèse principale (i.e., Main Hypothesis, H_A). Cette hypothèse est similaire à l'hypothèse nulle, mais inclut la taille d'effet dans sa formule mathématique (e.g., $H_M : M_1 - M_2 = 0 \pm ES$). Cette hypothèse met en avant l'erreur de Type I, qui correspond à faussement rejeter cette l'hypothèse principale. Dans ce cas, l'alpha (α) représente la probabilité de commettre l'erreur de Type I, qu'on cherche donc à minimiser. L'alpha va notamment permettre de déterminer une région critique dans la distribution permettant de statuer sur l'hypothèse (voir étape 8).
4. Fixer l'hypothèse alternative (i.e., Alternative Hypothesis : H_A). Cette hypothèse nouvelle diffère de l'hypothèse principale en admettant une différence claire (e.g., $H_A : M_1 - M_2 \neq 0 \pm ES$). Cette hypothèse met en avant l'erreur de Type II, qui correspond à faussement rejeter l'hypothèse alternative. Dans ce cas, le bêta (β) représente la probabilité de commettre l'erreur de Type II, qu'on cherche à minimiser.
5. Calculer la taille d'échantillon pour obtenir une puissance statistique satisfaisante. La puissance représente la probabilité de rejeter à raison l'hypothèse principale et donc d'accepter l'hypothèse alternative. La puissance se traduit notamment par l'opposé de l'erreur de Type II (i.e., $1-\beta$).
6. Calculer la valeur critique. La valeur critique est la valeur seuil permettant de décider de la significativité, elle est calculable avec des paramètres tels que le test, l'alpha ou la taille d'échantillon.

A posteriori


7. Calculer la valeur test. La valeur test correspond à la valeur obtenue en fonction des données et du test statistique utilisés selon des paramètres estimés de la population (e.g., variance) ou déduit théoriquement (e.g., modèle de distribution). Cette valeur se rapprochera de 0, si les données se rapprochent de la moyenne de l'hypothèse principale.

De la même façon, cette valeur s'éloignera de 0, si les données s'éloignent de la moyenne de l'hypothèse principale.

8. Décider en faveur de l'hypothèse principale ou alternative. Dans le cas où la puissance statistique est convenable, il est possible de faire deux choix. Si la valeur test se trouve dans la région critique, alors on rejette l'hypothèse principale pour accepter l'hypothèse alternative. Si la valeur test se trouve en dehors de la région critique alors on accepte l'hypothèse principale.

Cette approche de Neyman-Pearson permet de mettre en avant des concepts qui faisait défaut à l'approche de Fisher : les erreurs de Type I et II, ainsi que ce qui en découle, alpha, bêta, puissance, mais également la notion de taille d'effet.

L'approche NHST :




Chapitre 3.1.2. Incompréhension

Cette approche NHST, bien que dominante dans la discipline de la psychologie, est souvent mal comprise, notamment en ce qui concerne sa signification. Pour illustrer cette incompréhension, Haller et Krauss (2002) ont administré un questionnaire contenant six affirmations basées sur un énoncé statistique classique et ses implications/inférences causales. Les participants devaient répondre par vrai ou faux aux affirmations posées. Ce questionnaire a été administré à plusieurs groupes : des étudiants en psychologie, des professeurs enseignant la méthodologie statistique et des chercheurs n'enseignant pas cette méthodologie.

Les résultats de cette étude sont révélateurs. Tous les étudiants ont commis au moins une erreur, 89,7 % des chercheurs n'enseignant pas la méthodologie ont fait de même, et, de manière surprenante, 80 % des professeurs enseignant la méthodologie ont également eu au moins une mauvaise réponse. Le fait que 80 % des professeurs, supposés experts en méthodologie statistique, commettent des erreurs, est particulièrement alarmant. Si les enseignants eux-mêmes commettent des erreurs, il est logique de supposer que leurs étudiants en feront d'autant plus.

Cela suggère que les erreurs dans les inférences causales faites par les chercheurs peuvent entraîner des interprétations et des conclusions erronées dans leurs travaux. La question qui se pose alors est : qu'est-ce qui a conduit à cette situation ? Plusieurs facteurs peuvent être en cause, notamment des lacunes dans la formation en statistiques, des malentendus persistants sur les concepts statistiques fondamentaux, et une dépendance excessive à l'égard de pratiques méthodologiques traditionnelles sans une compréhension approfondie de leurs implications.



Le problème réside dans le fait que de nombreux chercheurs se sont conformés à l'approche NHST sans réellement en comprendre les tenants et les aboutissants. Gigerenzer (2004) aborde cette problématique en discutant du concept de « rituel nul » (i.e., null ritual), qui correspond à une routine simplifiée pour réaliser un test de significativité en quelques étapes. Pour l'auteur, cette routine peut être résumée en une phrase : fixer votre hypothèse nulle, calculer votre p-value avec un seuil alpha de 5 %, et toujours suivre cette procédure à la lettre. Ce rituel démontre

une certaine pauvreté statistique présente dans la littérature, alors même qu'il existe une multitude d'outils statistiques pertinents adaptés aux besoins spécifiques de la recherche. Gigerenzer va plus loin en suggérant que ce rituel constitue un obstacle majeur à la liberté intellectuelle des chercheurs, en grande partie en raison de la pression exercée par le système de publication académique. En effet, les chercheurs sont souvent contraints de se conformer à cette norme méthodologique dominante afin de s'assurer que leurs travaux soient acceptés et publiés dans des revues de renom. Cette dynamique peut limiter l'exploration de méthodologies alternatives et nuancer la diversité des approches statistiques dans la recherche scientifique.

Chapitre 3.1.3. Les degrés de liberté du chercheur

Un article fascinant explore le processus complet de la recherche expérimentale, depuis la conception de l'idée jusqu'à la publication finale. Au cours de ce processus, les chercheurs doivent prendre de nombreuses décisions pour des raisons théoriques et méthodologiques. Ces choix, appelés « les degrés de liberté du chercheur », peuvent avoir un impact sur les résultats des tests de significativité et, par extension, sur les interprétations et les conclusions tirées par les chercheurs (Simmons et al., 2011). Les degrés de liberté du chercheur sont présents à toutes les étapes de la recherche expérimentale : formulation des hypothèses, conception du design expérimental, réalisation de l'expérimentation, analyses des données et communication des études scientifiques.

Sur la base de ce concept, Wicherts et al. (2016) proposent un guide des différents degrés de liberté du chercheur pour chaque étape, dans le but d'aider les chercheurs dans leurs travaux futurs. La prise en compte de ces différents degrés de liberté du chercheur permettrait notamment de prévenir les faux positifs et de limiter l'inflation excessive des tailles d'effet. De plus, cela contribuerait à réduire la pratique du « p-hacking », qui consiste à ajuster certains paramètres pour obtenir une p-value significative. Par exemple, augmenter le nombre de participants peut faciliter le franchissement du seuil de significativité et aboutir à un résultat statistiquement significatif.

Une solution couramment admise est l'utilisation systématique du préenregistrement, qui doit être hautement transparent et couvrir toutes les étapes du processus de recherche expérimentale. Cela permettrait de renforcer la rigueur méthodologique et de réduire les biais liés aux degrés de liberté du chercheur.

Code	Related	Type of degrees of freedom
Hypothesizing		
T1	R6	Conducting explorative research without any hypothesis
T2		Studying a vague hypothesis that fails to specify the direction of the effect
Design		
D1	A8	Creating multiple manipulated independent variables and conditions
D2	A10	Measuring additional variables that can later be selected as covariates, independent variables, mediators, or moderators
D3	A5	Measuring the same dependent variable in several alternative ways
D4	A7	Measuring additional constructs that could potentially act as primary outcomes
D5	A12	Measuring additional variables that enable later exclusion of participants from the analyses (e.g., awareness or manipulation checks)
D6		Failing to conduct a well-founded power analysis
D7	C4	Failing to specify the sampling plan and allowing for running (multiple) small studies
Collection		
C1		Failing to randomly assign participants to conditions
C2		Insufficient blinding of participants and/or experimenters
C3		Correcting, coding, or discarding data during data collection in a non-blinded manner
C4	D7	Determining the data collection stopping rule on the basis of desired results or intermediate significance testing
Analyses		
A1		Choosing between different options of dealing with incomplete or missing data on <i>ad hoc</i> grounds
A2		Specifying pre-processing of data (e.g., cleaning, normalization, smoothing, motion correction) in an <i>ad hoc</i> manner
A3		Deciding how to deal with violations of statistical assumptions in an <i>ad hoc</i> manner
A4		Deciding on how to deal with outliers in an <i>ad hoc</i> manner
A5	D3	Selecting the dependent variable out of several alternative measures of the same construct
A6		Trying out different ways to score the chosen primary dependent variable
A7	D4	Selecting another construct as the primary outcome
A8	D1	Selecting independent variables out of a set of manipulated independent variables
A9	D1	Operationalizing manipulated independent variables in different ways (e.g., by discarding or combining levels of factors)
A10	D2	Choosing to include different measured variables as covariates, independent variables, mediators, or moderators
A11		Operationalizing non-manipulated independent variables in different ways
A12	D5	Using alternative inclusion and exclusion criteria for selecting participants in analyses
A13		Choosing between different statistical models
A14		Choosing the estimation method, software package, and computation of SEs
A15		Choosing inference criteria (e.g., Bayes factors, alpha level, sidedness of the test, corrections for multiple testing)
Reporting		
R1		Failing to assure reproducibility (verifying the data collection and data analysis)
R2		Failing to enable replication (re-running of the study)
R3		Failing to mention, misrepresenting, or misidentifying the study preregistration
R4		Failing to report so-called "failed studies" that were originally deemed relevant to the research question
R5		Misreporting results and <i>p</i> -values
R6	T1	Presenting exploratory analyses as confirmatory (HARKing)

Fig. Extrait de Wicherts et al., (2016)

Chapitre 3.1.4. Publication

Comme évoqué, la sanction de la publication fait référence au fait que les revues scientifiques ont tendance à accepter principalement des résultats statistiquement significatifs, au détriment de ceux qui ne le sont pas (i.e., biais de publication). En pratique, cela signifie que les revues préfèrent publier des résultats significatifs, ce qui entraîne une surabondance de résultats positifs et des biais de publication (Bakker et al., 2012). Par exemple, certains chercheurs pratiquent le *p*-hacking en manipulant les données, en arrondissant les *p*-values ou en omettant des mesures ou conditions expérimentales (John et al., 2012). La sanction de la publication a pour conséquence indirecte de créer des lacunes dans les données de deux manières. Premièrement, les études non publiées restent souvent ignorées, voire jamais utilisées. Deuxièmement, même si certaines études sont publiées, tous les résultats ne sont pas

nécessairement rapportés, certains étant mis de côté alors qu'ils pourraient fournir des données importantes.

Pour un chercheur, il est essentiel de pouvoir publier, car la publication joue un rôle crucial dans la reconnaissance scientifique de ses travaux. Cette importance professionnelle explique en partie les enjeux et les décisions prises par certains chercheurs. Dans le contexte de la répliquabilité des données liée à la recherche de significativité, Fanelli et al. (2017) suggèrent qu'un facteur de biais dans la science pourrait être lié à la productivité scientifique : « However, a scientist's early-career status, isolation, and lack of scientific integrity might be significant risk factors for producing unreliable results. » (pp. 3714). La nécessité de publier pour soutenir une thèse et obtenir un doctorat peut influencer la façon de penser d'un jeune chercheur et le pousser à une « obsession » des résultats significatifs pour être valorisée.




Fig. Dwan et al., 2013

Chapitre 3.1.5. Utilisation de la p-value

Au-delà de la publication ou de l'incompréhension, un autre problème réside dans la mauvaise utilisation de la p-value. En effet, son utilisation avec un seuil décisionnel repose sur une logique de pensée dichotomique, avec le rejet ou l'acceptation d'une hypothèse. Le résultat est ainsi catégorisé comme, soit statistiquement significatif, soit non significatif, avec le rejet ou l'acceptation de H_0 . De plus, l'adoption du seuil de 0,05 pour la valeur p est devenue une convention universelle dans les NHST. Cependant, ce seuil, comme tout seuil, a été choisi de manière arbitraire, ce qui comporte des défauts. La p-value étant une valeur continue, son importance varie incontestablement en fonction de son ampleur. Certains auteurs qualifient ainsi la significativité en fonction de l'ampleur de la p-value. Par exemple, un $p < 0,001$ serait considéré comme « hautement » significatif, tandis qu'un $p < 0,05$ serait considéré comme « peu » significatif.

Pour remédier à ce problème, plusieurs solutions ont été proposées par certains auteurs. Parmi celles-ci, on compte le choix d'une valeur seuil spécifique (Maier et Lakens, 2022 ; Mudge et al., 2012 ; Lakens et al., 2018), la redéfinition de la convention du seuil de 0,05 à 0,005 (Benjamin et al., 2018), ou encore l'abandon de la notion de seuil (McShane et al., 2019). Pour surmonter les problèmes des NHST, il serait intéressant de se concentrer davantage sur les tailles d'effet et d'adopter une approche méta-analytique en utilisant notamment les intervalles de confiance (Wilkinson, 1999 ; Cumming, 2013 ; 2014). En effet, la p-value seule ne serait pas un bon prédicteur, que ce soit pour les expérimentations exploratoires ou les réplifications de tout type (Cumming, 2008).

Nous avons vu que les NHST possédaient quelques limites, dans ce cas, doit-on continuer à l'utiliser ? En guise de conclusion, voilà une citation permettant de répondre à ceci : *Despite their repeated republication, the influence of the old statistics critiques on actual practice has not been significant. Like researchers in Bakan's era, researchers in our era rely heavily on p-values. Why is this the case? We think it is because there is actually no compelling reason to abandon the use of p-values. It is true that p-values are imperfect, but, for the types of questions that most psychologists are interested in answering, they are no more imperfect than confidence intervals, effect sizes, or Bayesian approaches. The biggest problem with p-values is that they can be mindlessly relied upon; however, when effect size estimates, confidence intervals, or Bayesian results are mindlessly relied upon, the results are at least as problematic. It is not the statistic that causes the problem, it is the mindlessness.* (pp. 529. Nelson et al., 2018)

Chapitre 3.2 Tests statistiques et conditions d'applications

Chapitre 3.2.1. Quel test statistique ?

Que ce soit pour des chercheurs expérimentés, de jeunes chercheurs ou des étudiants, personne n'échappe à l'utilisation des tests statistiques. Les logiciels statistiques, de plus en plus sophistiqués et offrant de multiples possibilités, peuvent vite devenir déroutants. Il est facile de se perdre, d'appuyer sur de nombreux boutons et d'obtenir des résultats sans vraiment comprendre ce que l'on fait. Comment savoir si la démarche analytique suivie est correcte ? Avant de recueillir des données, il est crucial de se poser la question de quels tests statistiques utilisés. Cette réflexion en amont est essentielle, car les tests statistiques permettent de répondre aux questions de recherche à partir des données collectées. De même qu'un design expérimental peut ne pas répondre à certaines questions de recherche en raison de sa conception, le type de données recueillies détermine le choix des tests statistiques appropriés.

Il est malheureusement très difficile de maîtriser la multitude de tests statistiques existants ainsi que les avantages et inconvénients de chacun. Pour les étudiants ou les jeunes chercheurs, il est courant de collecter des données et de décider ensuite quel test utiliser. Toutefois, à moins d'avoir une idée précise de la méthode à suivre (e.g., ANOVA magique), il est fréquent de se retrouver dans le flou quant au test à utiliser. Comme mentionné précédemment, les tests statistiques doivent refléter les choix concernant le type de données et les questions de recherche.

Dans cette optique, Howell (2016) propose un arbre de décision pour aider à déterminer quel test statistique est le plus approprié. Cet arbre de décision guide les chercheurs en fonction des types de données et de l'intérêt du chercheur. Par exemple, il peut aider à décider si un test paramétrique ou non paramétrique est nécessaire, si des comparaisons de moyennes ou des analyses de variance sont appropriées, ou encore si des relations entre variables doivent être explorées à l'aide de corrélations ou de régressions. En suivant cet arbre de décision, les chercheurs peuvent systématiquement choisir le test statistique le plus pertinent, en tenant compte des spécificités de leurs données et de leurs hypothèses.




Fig. Arbre de décision par Howell (2016)

Chapitre 3.2.2. Pourquoi conditions d'applications ?

Une fois que le test statistique approprié est déterminé, il est crucial de vérifier ce qu'on appelle les conditions d'application (i.e., assumption checks). Chaque test statistique repose sur des hypothèses spécifiques qui assurent la validité de ses résultats. Par exemple, le test t de Student suppose que les données suivent une distribution normale pour déterminer si les différences observées sont significatives et pour décider du rejet ou non de l'hypothèse nulle (H_0). Si les données ne suivent pas une distribution normale, l'utilisation de ce test n'est pas appropriée, car les inférences statistiques en seraient compromises.

La violation des conditions d'application peut entraîner plusieurs problèmes : une augmentation des erreurs de type I (faux positifs) et de type II (faux négatifs), des biais dans la précision des estimations de paramètres et des intervalles de confiance, ce qui peut à son tour conduire à des problèmes de réplicabilité et à des interprétations erronées des résultats. Cependant, ces conditions sont parfois négligées par les chercheurs. Hoekstra et al. (2012) suggèrent que cela pourrait être dû à une méconnaissance des conditions d'applications, à un manque de compétences pour les vérifier, à une ignorance des risques associés à leur violation, ou à une incertitude sur la manière de remédier à ces violations.

Pour assurer la validité et la fiabilité des analyses statistiques, il est essentiel de comprendre et de vérifier les conditions d'application de chaque test utilisé. Cela implique de tester la normalité des données, l'homogénéité des variances, l'indépendance des observations, entre autres. Dans cette section, nous nous investiguons uniquement les tests de comparaison de moyenne (T-Test et ANOVA) et les conditions d'applications liées à la normalité et l'égalité de variances.




Fig. Exemple de distribution normale pour t-test

Chapitre 3.2.3. Normalité

Comme mentionné précédemment, de nombreux tests statistiques reposent sur l'hypothèse de la normalité des données. Il est donc crucial de vérifier cette normalité avant de procéder aux analyses. Il existe deux approches complémentaires pour évaluer la normalité des données : les tests statistiques et les représentations visuelles.

Le test de Shapiro-Wilk est le plus couramment utilisé pour tester la normalité des données. Dans ce test, l'hypothèse nulle (H_0) postule que les données suivent une distribution normale, tandis que l'hypothèse alternative (H_1) postule qu'elles ne suivent pas une distribution normale. Si le résultat du test est non significatif ($p > 0,05$), on ne peut pas rejeter l'hypothèse nulle, ce qui suppose que les données suivent une distribution normale.

En complément, il est recommandé d'utiliser des représentations visuelles comme le Q-Q Plot (quantile-quantile plot). Un Q-Q Plot compare les quantiles de l'échantillon de données aux quantiles d'une distribution théorique (normale dans ce cas). Si les points sur le Q-Q Plot suivent approximativement une ligne droite, cela indique que les données suivent une distribution normale. En revanche, si les points s'écartent significativement de la ligne droite, cela suggère que les données ne suivent pas une distribution normale, ce qui viole l'hypothèse de normalité.

L'utilisation conjointe de tests statistiques et de représentations visuelles permet une évaluation plus robuste de la normalité des données. Tandis que le test de Shapiro-Wilk fournit une évaluation statistique, le Q-Q Plot offre une vérification visuelle du comportement des données. Si les deux méthodes convergent, cela renforce la confiance dans l'évaluation de la normalité. Dans le cas contraire, une analyse plus approfondie est nécessaire pour comprendre les caractéristiques des données et choisir des méthodes statistiques appropriées.




Fig. Q-Q Plot avec une distribution non normale vs normale

Que faire si cette condition d'application est violée ? Deux solutions existent comme utiliser un test non paramétrique ou transformer les données. L'avantage des tests non paramétriques est qu'ils ne nécessitent pas l'hypothèse de normalité des données. Ces tests reposent sur le classement des données plutôt que sur leurs valeurs brutes. Par exemple, le test de Mann-Whitney est une alternative au test t pour deux échantillons indépendants. Cependant, un inconvénient majeur des tests non paramétriques est qu'ils sont généralement moins puissants statistiquement que les tests paramétriques et fournissent moins d'informations sur les données (Asmare et Begashaw, 2018). Une autre approche consiste à transformer les données pour les rendre normales. Il existe plusieurs types de transformations (e.g., logarithmique, racine carrée, Box-Cox) qui peuvent être utilisées pour normaliser les données. La transformation Box-Cox est particulièrement utile, car elle cherche automatiquement la meilleure transformation pour

normaliser les données (Osborne, 2010). Cette méthode ajuste les données selon une transformation paramétrique optimale, facilitant ainsi l'application des tests paramétriques tout en respectant leurs conditions d'application.

Chapitre 3.2.4. Variance

Une deuxième condition d'application concerne l'égalité des variances (i.e., homoscedasticité). Concrètement, les données provenant de groupes ou de conditions expérimentales différents doivent présenter la même variance. Un concept similaire, mais spécifique à l'ANOVA à mesures répétées est la sphéricité. Pour vérifier l'égalité des variances, on peut utiliser le test de Levene dans le cadre d'un T-Test ou d'une ANOVA à un facteur. Pour une ANOVA à mesures répétées, c'est le test de Mauchly qui est approprié. Dans ces tests, l'hypothèse nulle (H_0) suppose une égalité des variances, tandis que l'hypothèse alternative (H_1) suppose une différence des variances. Ainsi, si le résultat est significatif, on peut rejeter H_0 et conclure à une différence de variances. Une autre méthode consiste à utiliser un plot des résidus pour une vérification visuelle. Dans ce graphique, les résidus doivent être répartis aléatoirement et de manière uniforme de part et d'autre de la droite pour que l'homoscédasticité soit considérée comme respectée.




Fig. Exemple de residuals plots

Si cette condition d'application est violée, il est conseillé de réaliser une correction, comme celle de Greenhouse-Geisser dans le cas d'une ANOVA à mesures répétées, par exemple. Cette correction entraîne une réduction des degrés de liberté dans les facteurs où la condition est

violée. Cette diminution modifie la p-value associée à ce facteur, ce qui peut transformer un résultat significatif en un résultat non significatif, mais c'est une pratique nécessaire pour assurer la validité des conclusions.

Que ce soit pour la normalité ou l'égalité des variances, il est essentiel d'être complètement transparent sur la démarche analytique lors de la publication scientifique.

Chapitre 3.3 Outliers

Une question majeure dans de nombreuses recherches scientifiques concerne la détection et la gestion des valeurs aberrantes, communément appelées outliers. Avant d'aborder ce concept, il est crucial de le définir. Walfish (2006) définit un outlier comme « une observation qui semble incohérente par rapport aux autres observations de l'ensemble de données ». Par conséquent, un outlier a une faible probabilité d'apparaître et de provenir de la même distribution statistique que l'ensemble des données. En d'autres termes, il s'agit d'une valeur qui se situe anormalement en dehors du schéma général d'une distribution de variables. Il est important de distinguer l'outlier de la valeur extrême, qui a également une faible probabilité d'apparaître, mais dont on ne peut pas prouver qu'elle provient d'une distribution différente. Les outliers peuvent résulter de divers facteurs tels que des erreurs de saisie de données ou des erreurs de réponse des participants. Ils peuvent également représenter une tendance différente de celle de la majorité des données tout en ayant un poids significatif dans l'ensemble des données. Dans tous les cas, les outliers introduisent un biais dans les indices statistiques (e.g., la moyenne), pouvant entraîner une sous-estimation ou une surestimation des résultats.

Chapitre 3.3.1. Méthode visuelle

Pour détecter les outliers, il existe une multitude de méthodes, chacune présentant ses avantages et ses inconvénients. Globalement, ces méthodes se divisent en deux grandes catégories : les méthodes visuelles et les méthodes statistiques. Parmi les méthodes visuelles, la plus connue et couramment utilisée est celle des « box and whiskers plots », ou boxplots. En résumé, un boxplot permet d'obtenir des informations telles que la médiane, l'écart interquartile et les valeurs extrêmes (haute et basse) de la distribution des données. De plus, il met en évidence les valeurs qui se trouvent en dehors des extrémités, représentant ainsi les outliers. Cette méthode offre une visualisation facile et robuste aux variations, car elle se base sur la médiane de la distribution des données. Cependant, elle peut être moins efficace pour détecter les outliers dans le cadre de distributions non normales ou lors d'analyses multivariées.




Fig. Exemple boxplot

Chapitre 3.3.2. Méthodes statistiques

En ce qui concerne les méthodes statistiques, l'une des plus connues est l'utilisation des résidus studentisés. Ces résidus ajustent les résidus bruts en tenant compte de l'incertitude dans la prédiction d'un modèle statistique, tel qu'une régression. Ils sont obtenus en divisant les résidus par l'écart type estimé. Ensuite, la valeur obtenue est comparée à un seuil prédéfini : si ce seuil est dépassé, la valeur est considérée comme un outlier. Généralement, les seuils utilisés sont de 2 ou 3, considérés comme conservateurs (Ahmadiyeh et al., 2023). Selon le seuil choisi, une valeur peut être considérée comme une valeur extrême ou un outlier. En général, plus le seuil est élevé, moins les valeurs extrêmes sont considérées comme des outliers. Cette méthode est intéressante, car elle tient compte des relations multivariées, en particulier des relations entre variables. Cependant, elle fonctionne mieux avec des relations linéaires classiques et reste sensible aux valeurs extrêmes pouvant fausser les résultats des outliers.

Une fois qu'une observation est identifiée comme un outlier, la question suivante est de savoir comment la traiter. Tout d'abord, si l'erreur provient d'une erreur de saisie de données ou d'une autre source facilement identifiable, il suffit de nettoyer les données pour résoudre le problème. Cependant, si l'observation correspond à une tendance différente de la distribution, il est nécessaire de déterminer si elle est influente sur l'ensemble des données. Pour évaluer l'influence d'une observation, les outils statistiques tels que le levier (leverage) et la distance de Cook (Cook's Distance) sont souvent utilisés dans le contexte de régressions linéaires (Dhakal, 2017). Le levier mesure dans quelle mesure une observation individuelle s'éloigne de la


moyenne des variables explicatives. Les observations avec des leviers élevés ont un potentiel accru d'influencer la forme générale du modèle de régression. En revanche, la distance de Cook évalue l'influence globale d'une observation sur l'ensemble du modèle de régression, en tenant compte des changements simultanés dans la pente et l'ordonnée à l'origine. Des valeurs élevées de la distance de Cook indiquent des observations qui peuvent significativement affecter les résultats du modèle.

En résumé, le levier évalue l'extrémité d'une observation dans l'espace des variables explicatives, tandis que la distance de Cook évalue l'influence totale de cette observation sur l'ensemble du modèle de régression. Les deux outils sont importants pour identifier les points influents dans une analyse de régression. Ainsi, pour exclure une observation de l'analyse, il est judicieux de considérer non seulement si elle est qualifiée d'outlier selon les résidus studentisés, mais aussi si elle est considérée comme influente selon la distance de Cook ou le levier.

Chapitre 3.3.3. Clusters


Pour les larges échantillons pouvant présenter plusieurs outliers, l'utilisation de cluster est une solution intéressante à explorer (Rousseeuw et Hubert, 2011). Les clusters permettent de regrouper des observations similaires en fonction de leurs caractéristiques. Pour cela, il existe deux méthodes populaires : k-means et hiérarchisation.

La méthode k-means consiste à assigner aux observations, un nombre k de clusters tout en réduisant la variance intra-cluster. Le nombre k est spécifié au préalable selon les suppositions du chercheur ou de la littérature. Par exemple, lors d'études de marché sur un produit, on pourrait supposer qu'il existe deux types d'acheteur impulsif ou réflexif. Le nombre k sera alors de 2 et les observations seront assignées aux deux clusters. Cette méthode est donc assez simple dans son fonctionnement, mais il peut être compliqué de spécifier le bon nombre k, surtout avec des clusters complexes.



Ex. k-means

La méthode hiérarchique consiste à construire une hiérarchie de cluster avec l'association de groupes d'observations similaires. Cette méthode, quant à elle, ne nécessite pas de spécifier à l'avance un nombre de clusters et peut s'adapter à des structures complexes de cluster. Cependant, sur de trop grands échantillons, cette méthode peut perdre en efficacité en raison de sa complexité.



Ex. Cluster hiérarchique

Références Chapitre 1

Fitzner, K. (2007). Reliability and validity a quick review. *The Diabetes Educator*, 33(5), 775-780. <https://doi.org/10.1177/0145721707308172>

Hedge, C., Powell, G. & Sumner, P. (2017). The reliability paradox: Why robust cognitive tasks do not produce reliable individual differences. *Behav Res* 50, 1166–1188). <https://doi.org/10.3758/s13428-017-0935-1>

Koo, T. K., & Li, M. Y. (2016). A guideline of selecting and reporting intraclass correlation coefficients for reliability research. *Journal of chiropractic medicine*, 15(2), 155-163. <https://doi.org/10.1016/j.jcm.2016.02.012>

Lance, C. E., Butts, M. M., & Michels, L. C. (2006). The sources of four commonly reported cutoff criteria: What did they really say?. *Organizational research methods*, 9(2), 202-220. <https://doi.org/10.1177/1094428105284919>

Moshontz, H., Campbell, L., Ebersole, C. R., IJzerman, H., Urry, H. L., Forscher, P. S., ... & Chartier, C. R. (2018). The Psychological Science Accelerator: Advancing psychology through a distributed collaborative network. *Advances in Methods and Practices in Psychological Science*, 1(4), 501-515. <https://doi.org/10.1177/2515245918797607>

Nunnally, J. C. (1975). Psychometric theory—25 years ago and now. *Educational Researcher*, 4(10), 7-21.

Parsons, S., Kruijt, A. W., & Fox, E. (2019). Psychological science needs a standard practice of reporting the reliability of cognitive-behavioral measurements. *Advances in Methods and Practices in Psychological Science*, 2(4), 378-395. <https://doi.org/10.1177/2515245919879695>

Pollet, T. V., & Saxton, T. K. (2019). How diverse are the samples used in the journals ‘Evolution & Human Behavior’ and ‘Evolutionary Psychology’?. *Evolutionary Psychological Science*, 5, 357-368. <https://doi.org/10.31219/osf.io/7h24p>

Revelle, W., & Condon, D. M. (2019). Reliability from α to ω : A tutorial. *Psychological assessment*, 31(12), 1395-1411. <https://doi.org/10.1037/pas0000754>

Silberzahn, R., Uhlmann, E. L., Martin, D. P., Anselmi, P., Aust, F., Awtrey, E., ... & Nosek, B. A. (2018). Many analysts, one data set: Making transparent how variations in analytic

choices affect results. *Advances in Methods and Practices in Psychological Science*, 1(3), 337-356. <https://doi.org/10.1177/2515245917747646>

Stanley, D. J., & Spence, J. R. (2014). Expectations for replications: Are yours realistic?. *Perspectives on Psychological Science*, 9(3), 305-318. <https://doi.org/10.1177/1745691614528518>

Vazire, S., Schiavone, S. R., & Bottesini, J. G. (2022). Credibility beyond replicability: Improving the four validities in psychological science. *Current Directions in Psychological Science*, 31(2), 162-168. <https://doi.org/10.1177/09637214211067779>

Wiernik, B. M., & Dahlke, J. A. (2020). Obtaining unbiased results in meta-analysis: The importance of correcting for statistical artifacts. *Advances in Methods and Practices in Psychological Science*, 3(1), 94-123. <https://doi.org/10.1177/2515245919885611>

Wilmer, J. B. (2008). How to use individual differences to isolate functional organization, biology, and utility of visual functions; with illustrative proposals for stereopsis. *Spatial vision*, 21(6), 561-579. <https://doi.org/10.1163%2F156856808786451408>

Références Chapitre 2

- Baguley, T. (2009). Standardized or simple effect size: What should be reported?. *British journal of psychology*, 100(3), 603-617. <https://doi.org/10.1348/000712608X377117>
- Borenstein, M., Cooper, H., Hedges, L., & Valentine, J. (2009). Effect sizes for continuous data. *The handbook of research synthesis and meta-analysis*, 2, 221-235.
- Charness, G., Gneezy, U., & Kuhn, M. A. (2012). Experimental methods: Between-subject and within-subject design. *Journal of economic behavior & organization*, 81(1), 1-8.
- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2nd ed.). Hillsdale, NJ: Erlbaum
- Crandall, C. S., & Sherman, J. W. (2016). On the scientific superiority of conceptual replications for scientific progress. *Journal of Experimental Social Psychology*, 66, 93-99.
- Cumming, G., & Finch, S. (2005). Inference by Eye: *Confidence Intervals and How to Read Pictures of Data*. *American Psychologist*, 60(2), 170–180. <https://doi.org/10.1037/0003-066X.60.2.170>
- Cumming, G., Williams, J., & Fidler, F. (2004). Replication and researchers' understanding of confidence intervals and standard error bars. *Understanding statistics*, 3(4), 299-311. https://doi.org/10.1207/s15328031us0304_5
- Dienes, Z. (2014). Using Bayes to get the most out of non-significant results. *Frontiers in psychology*, 5, 85883. <https://doi.org/10.3389/fpsyg.2014.00781>
- Ellis, P. D. (2010). *The essential guide to effect sizes: Statistical power, meta-analysis, and the interpretation of research results*. Cambridge university press.
- Faul, F., Erdfelder, E., Lang, A. G., & Buchner, A. (2007). G* Power 3: A flexible statistical power analysis program for the social, behavioral, and biomedical sciences. *Behavior research methods*, 39(2), 175-191. <https://doi.org/10.3758/BF03193146>
- Faul, F., Erdfelder, E., Buchner, A., & Lang, A. G. (2009). Statistical power analyses using G* Power 3.1: Tests for correlation and regression analyses. *Behavior research methods*, 41(4), 1149-1160. <https://doi.org/10.3758/BRM.41.4.1149>

- Funder, D. C., & Ozer, D. J. (2019). Evaluating effect size in psychological research: Sense and nonsense. *Advances in Methods and Practices in Psychological Science*, 2(2), 156-168. <https://doi.org/10.3758/BRM.41.4.1149>
- Grissom, R. J., & Kim, J. J. (2005). Effect sizes for research: A broad practical approach. Mahwah, NJ: Erlbaum.
- Grissom, R. J., & Kim, J. J. (2012). Effect sizes for research: Univariate and multivariate applications (2nd ed.). New York, NY: Routledge.
- Hoekstra, R., Morey, R. D., Rouder, J. N., & Wagenmakers, E. J. (2014). Robust misinterpretation of confidence intervals. *Psychonomic bulletin & review*, 21, 1157-1164. <https://doi.org/10.3758/s13423-013-0572-3>
- Kang, H. (2021). Sample size determination and power analysis using the G* Power software. *Journal of educational evaluation for health professions*, 18. <http://dx.doi.org/10.3352/JEEHP.2021.18.17>
- Kelley, K., & Preacher, K. J. (2012). On effect size. *Psychological Methods*, 17(2), 137–152. <https://doi.org/10.1037/a0028086>
- Kirk, R. E. (2002). Experimental design. In I. B. Weiner (Series ed.) & J. Schinka & W. F. Velicer (Vol. eds.), *Handbook of psychology: Vol. 2. Research methods in psychology* (pp. 3–32). New York, NY: Wiley.
- Koole, S. L., & Lakens, D. (2012). Rewarding replications: A sure and simple way to improve psychological science. *Perspectives on Psychological Science*, 7(6), 608-614.
- Lakens, D. (2013). Calculating and reporting effect sizes to facilitate cumulative science: a practical primer for t-tests and ANOVAs. *Frontiers in psychology*, 4, 62627. <https://doi.org/10.3389/fpsyg.2013.00863>
- Lakens, D. (2017). Equivalence tests: A practical primer for t tests, correlations, and meta-analyses. *Social psychological and personality science*, 8(4), 355-362. <https://doi.org/10.1177/1948550617697177>
- Lakens, D. (2022). Sample size justification. *Collabra: Psychology*, 8(1), 33267. <https://doi.org/10.1525/collabra.33267>

Lakens, D., & Caldwell, A. R. (2021). Simulation-based power analysis for factorial analysis of variance designs. *Advances in Methods and Practices in Psychological Science*, 4(1), 2515245920951503. <https://doi.org/10.1177/2515245920951503>

Lakens, D., McLatchie, N., Isager, P. M., Scheel, A. M., & Dienes, Z. (2020). Improving inferences about null effects with Bayes factors and equivalence tests. *The Journals of Gerontology: Series B*, 75(1), 45-57. <https://doi.org/10.1093/geronb/gby065>

Lakens, D., Scheel, A. M., & Isager, P. M. (2018). Equivalence testing for psychological research: A tutorial. *Advances in Methods and Practices in Psychological Science*, 1(2), 259-269. <https://doi.org/10.1177/2515245918770963>

Miller, J., & Schwarz, W. (2018). Implications of individual differences in on-average null effects. *Journal of Experimental Psychology: General*, 147(3), 377-397. <https://doi.org/10.1037/xge0000367>

Meyvis, T., & Van Osselaer, S. M. (2018). Increasing the power of your study by increasing the effect size. *Journal of Consumer Research*, 44(5), 1157-1173. <https://doi.org/10.1093/jcr/ucx110>

Nelson, L. D., Simmons, J., & Simonsohn, U. (2018). Psychology's renaissance. *Annual review of psychology*, 69(1), 511-534. <https://doi.org/10.1146/annurev-psych-122216-011836>

Nosek, B. A., Hardwicke, T. E., Moshontz, H., Allard, A., Corker, K. S., Dreber, A., ... & Vazire, S. (2022). Replicability, robustness, and reproducibility in psychological science. *Annual review of psychology*, 73(1), 719-748. <https://doi.org/10.1146/annurev-psych-020821-114157>

Patil, P., Peng, R. D., & Leek, J. T. (2016). What should researchers expect when they replicate studies? A statistical view of replicability in psychological science. *Perspectives on Psychological Science*, 11(4), 539-544.

Preacher, K. J., & Kelley, K. (2011). Effect size measures for mediation models: Quantitative strategies for communicating indirect effects. *Psychological Methods*, 16(2), 93-115. <https://doi.org/10.1037/a0022658>

Rosenthal, R. (1994). Parametric measures of effect size. In H. Cooper & L. V. Hedges (Eds.), *The handbook of research synthesis* (pp. 231–244). New York, NY: Russell Sage Foundation

Ruscio, J. (2008). A probability-based measure of effect size: Robustness to base rates and other factors. *Psychological Methods*, 13(1), 19–30. <https://doi.org/10.1037/1082-989X.13.1.19>

Schäfer, T., & Schwarz, M. A. (2019). The meaningfulness of effect sizes in psychological research: Differences between sub-disciplines and the impact of potential biases. *Frontiers in psychology*, 10, 813. <https://doi.org/10.3389/fpsyg.2019.00813>

Schmidt, S. (2009). Shall we really do it again? The powerful concept of replication is neglected in the social sciences. *Review of general psychology*, 13(2), 90-100. <https://doi.org/10.1037/a0015108>

Silberzahn, R., Uhlmann, E. L., Martin, D. P., Anselmi, P., Aust, F., Awtrey, E., ... & Nosek, B. A. (2018). Many analysts, one data set: Making transparent how variations in analytic choices affect results. *Advances in Methods and Practices in Psychological Science*, 1(3), 337-356. <https://doi.org/10.1177/2515245917747646>

Smith, P. L., & Little, D. R. (2018). Small is beautiful: In defense of the small-N design. *Psychonomic Bulletin & Review*. <https://doi.org/10.3758/s13423-018-1451-8>

Steenen, S., Tuerlinckx, F., Gelman, A., & Vanpaemel, W. (2016). Increasing transparency through a multiverse analysis. *Perspectives on Psychological Science*, 11(5), 702-712. <https://doi.org/10.1177/1745691616658637>

Szucs, D., & Ioannidis, J. P. (2017). Empirical assessment of published effect sizes and power in the recent cognitive neuroscience and psychology literature. *PLoS biology*, 15(3), e2000797. <https://doi.org/10.1371/journal.pbio.2000797>

Vacha-Haase, T., & Thompson, B. (2004). How to Estimate and Interpret Various Effect Sizes. *Journal of Counseling Psychology*, 51(4), 473–481. <https://doi.org/10.1037/0022-0167.51.4.473>

Wagenmakers, E. J., Verhagen, J., Ly, A., Bakker, M., Lee, M. D., Matzke, D., ... & Morey, R. D. (2015). A power fallacy. *Behavior Research Methods*, 47(4), 913-917. <https://doi.org/10.3758/s13428-014-0517-4>

Références Chapitre 3

Ahmadiyeh, F., Sajedi-Amin, S., Kafili-Hajlari, T., & Naseri, A. (2023). Roadmap for outlier detection in univariate linear calibration in analytical chemistry: Tutorial review. *Journal of Chemometrics*, 37(1), e3460. <https://doi.org/10.1002/cem.3460>

Asmare, E., & Begashaw, A. (2018). Review on parametric and nonparametric methods of efficiency analysis. *Biostatistics and Bioinformatics*, 2(2), 1-7.

Bakker, M., Van Dijk, A., & Wicherts, J. M. (2012). The rules of the game called psychological science. *Perspectives on Psychological Science*, 7(6), 543-554. <https://doi.org/10.1177/1745691612459060>

Benjamin, D. J., Berger, J. O., Johannesson, M., Nosek, B. A., Wagenmakers, E. J., Berk, R., ... & Johnson, V. E. (2018). Redefine statistical significance. *Nature human behaviour*, 2(1), 6-10. <https://doi.org/10.1038/s41562-017-0189-z>

Cumming, G. (2008). Replication and p intervals: p values predict the future only vaguely, but confidence intervals do much better. *Perspectives on psychological science*, 3(4), 286-300. <https://doi.org/10.1111/j.1745-6924.2008.00079.x>

Cumming, G. (2013). *Understanding the new statistics: Effect sizes, confidence intervals, and meta-analysis*. Routledge.

Cumming, G. (2014). The new statistics: Why and how. *Psychological science*, 25(1), 7-29. <https://doi.org/10.1177/0956797613504966>

Dhakal, C. P. (2017). Dealing with outliers and influential points while fitting regression. *Journal of Institute of Science and Technology*, 22(1), 61-65.

Dwan, K., Gamble, C., Williamson, P. R., Kirkham, J. J., & Reporting Bias Group. (2013). Systematic review of the empirical evidence of study publication bias and outcome reporting bias—an updated review. *PloS one*, 8(7), e66844. <https://doi.org/10.1371/journal.pone.0066844>

Fanelli, D., Costas, R., & Ioannidis, J. P. (2017). Meta-assessment of bias in science. *Proceedings of the National Academy of Sciences*, 114(14), 3714-3719. <https://doi.org/10.1073/pnas.1618569114>

Gigerenzer, G. (2004). Mindless statistics. *The Journal of Socio-Economics*, 33(5), 587-606.
<https://doi.org/10.1016/j.socec.2004.09.033>

John, L. K., Loewenstein, G., & Prelec, D. (2012). Measuring the prevalence of questionable research practices with incentives for truth telling. *Psychological science*, 23(5), 524-532.
<https://doi.org/10.1177/0956797611430953>

Haller, H., & Krauss, S. (2002). Misinterpretations of significance: A problem students share with their teachers. *Methods of psychological research*, 7(1), 1-20.
<https://doi.org/10.5283/epub.34338>

Kwak, S. K., & Kim, J. H. (2017). Statistical data preparation: management of missing values and outliers. *Korean journal of anesthesiology*, 70(4), 407-411.
<https://doi.org/10.4097%2Fkjae.2017.70.4.407>

Lakens, D., Adolphi, F. G., Albers, C. J., Anvari, F., Apps, M. A., Argamon, S. E., ... & Zwaan, R. A. (2018). Justify your alpha. *Nature human behaviour*, 2(3), 168-171.
<https://doi.org/10.1038/s41562-018-0311-x>

Maier, M., & Lakens, D. (2022). Justify your alpha: A primer on two practical approaches. *Advances in Methods and Practices in Psychological Science*, 5(2), 25152459221080396. <https://doi.org/10.1177/25152459221080396>

McShane, B. B., Gal, D., Gelman, A., Robert, C., & Tackett, J. L. (2019). Abandon statistical significance. *The American Statistician*, 73(sup1), 235-245.
<https://doi.org/10.1080/00031305.2018.1527253>

Mudge, J. F., Baker, L. F., Edge, C. B., & Houlahan, J. E. (2012). Setting an optimal α that minimizes errors in null hypothesis significance tests. *PloS one*, 7(2), e32734.
<https://doi.org/10.1371/journal.pone.0032734>

Osborne, J. W., & Waters, E. (2019). Four assumptions of multiple regression that researchers should always test. *Practical assessment, research, and evaluation*, 8(1), 2.

Osborne, J. (2010). Improving your data transformations: Applying the Box-Cox transformation. *Practical Assessment, Research, and Evaluation*, 15(1).
<https://doi.org/10.7275/qbpc-gk17>

Perezgonzalez, J. D. (2015). Fisher, Neyman-Pearson or NHST? A tutorial for teaching data testing. *Frontiers in psychology*, 6, 223. <https://doi.org/10.3389/fpsyg.2015.00223>

Rousseeuw, P. J., & Hubert, M. (2011). Robust statistics for outlier detection. *Wiley interdisciplinary reviews: Data mining and knowledge discovery*, 1(1), 73-79. <https://doi.org/10.1002/widm.2>

Simmons, J. P., Nelson, L. D., & Simonsohn, U. (2011). False-Positive Psychology: Undisclosed Flexibility in Data Collection and Analysis Allows Presenting Anything as Significant. *Psychological Science*, 22(11), 1359-366. <https://doi.org/10.1177/0956797611417632>

Walfish, S. (2006). A review of statistical outlier methods. *Pharmaceutical technology*, 30(11), 82.

Wada, K. (2020). Outliers in official statistics. *Japanese Journal of Statistics and Data Science*, 3(2), 669-691. Wada, K. (2020). Outliers in official statistics. *Japanese Journal of Statistics and Data Science*, 3(2), 669-691. <https://doi.org/10.1007/s42081-020-00091-y>

Wicherts, J. M., Veldkamp, C. L., Augusteyn, H. E., Bakker, M., Van Aert, R., & Van Assen, M. A. (2016). Degrees of freedom in planning, running, analyzing, and reporting psychological studies: A checklist to avoid p-hacking. *Frontiers in psychology*, 1832. <https://doi.org/10.3389/fpsyg.2016.01832>

Wilkinson, L., & Task Force on Statistical Inference, American Psychological Association, Science Directorate. (1999). Statistical methods in psychology journals: Guidelines and explanations. *American Psychologist*, 54(8), 594–604. <https://doi.org/10.1037/0003-066X.54.8.594>